

Universidad de Guayaquil

Facultad de Ciencias Matemáticas y
Física

Clasificación del Riesgo de Inundación
por Parroquia en Zonas Lluviosas del
Ecuador

Aprendizaje Automático

Proyecto Final del Parcial

Integrantes:

Caicho Almeida Shanney Odessa
Cedeño Pinto Scarlett Yamilett
Salavarria Estrada Alejandra Janelly
Ordoñez Soto Cosme Alexander

29 de Junio del 2026

0.1 Introducción

En el Ecuador la exposición a diversos eventos meteorológicos difíciles es mayor, especialmente las inundaciones debido a su ubicación geográfica, su variabilidad climática estacional y especialmente la influencia del fenómeno de El Niño, aquí datos históricos recopilados muestran que mayormente la incidencia de estos eventos se centran en regiones de la Costa y Amazonía, siendo las provincias de Los Ríos y Guayas algunas de las zonas más afectadas debido a su topografía, las cercanías a cuencas hidrográficas y su alta densidad poblacional en zonas vulnerables.

Este proyecto tiene como finalidad diseñar e implementar un modelo de clasificación supervisada que permita asignar a cada parroquia de las provincias de Los Ríos y Guayas una categoría o escala de riesgo de inundación, la cual se realizó integrando variables como: Precipitación acumulada, topografía (altitud y pendiente del terreno) y distancia a cuerpos de agua. Se intentó además incorporar la densidad poblacional (INEC) como variable socio-territorial, aunque su integración final quedó pendiente por incompatibilidad en el esquema de columnas del archivo fuente, lo cual se documenta como limitación del estudio. Este proyecto construyó la variable objetivo a partir de criterios técnicos documentados, realizado en la recopilación de datos, la limpieza y transformación de datos provenientes de diferentes fuentes oficiales.

El presente informe documenta la metodología aplicada, los resultados obtenidos mediante distintos algoritmos de clasificación incluyendo regresión logística, árboles de decisión y modelos de ensamble y las conclusiones derivadas del análisis, con el fin de aportar una herramienta replicable que apoye la gestión local del riesgo de inundación en el país.

0.2 Descripción de los datos y su origen

En este proyecto se utilizaron diferentes tipos de datos obtenidos de fuentes de datos oficiales y abiertas: División político administrativa: Se implementó un shapefile con la división territorial del Ecuador, el cual contiene los polígonos georreferenciados de todas las parroquias del país con sus códigos político administrativos (DPA), con este archivo se filtraron las parroquias pertenecientes a las provincias objetivo: Los Ríos y Guayas.

Precipitación: En precipitaciones se usaron los registros históricos de precipitación mensual por estación meteorológica de la INAMHI correspondiente a los períodos 1960–2019, con 947 estaciones a nivel nacional y 20.588 registros anuales. Cada registro contiene los valores de precipitación mensual (enero a diciembre) en milímetros, además de las coordenadas geográficas y la altitud de cada estación. Se calculó la precipitación acumulada anual por estación y, posteriormente, su promedio histórico, el cual fue asignado a cada parroquia mediante una unión espacial por proximidad.

Densidad poblacional: Se utilizó el tabulado de densidad poblacional por parroquia elaborado a partir del Censo de Población y Vivienda del INEC, que incluye la población total, la superficie en km^2 y la densidad poblacional (hab/km^2) para las 1.042 parroquias del país.

De manera complementaria se derivaron variables a partir de las fuentes anteriormente recopiladas: la altitud media de cada parroquia, obtenida consultando datos SRTM por medio de la librería "srtm.py" aplicada al centroide de cada polígono parroquial; y la pendiente aproximada, calculada como el rango altitudinal entre cinco puntos aleatorios dentro de cada polígono, constituyendo esta última la variable derivada requerida por el proyecto. Adicionalmente, se construyó una segunda variable derivada correspondiente a la diferencia de pendiente respecto a las parroquias vecinas, calculada como la desviación del valor de pendiente de cada parroquia frente al promedio de sus vecinas geográficas, con el fin de capturar el contraste topográfico relativo dentro de la zona de estudio.

La distancia a cuerpos de agua se calculó a partir de un shapefile de las cuencas hidrográficas del Ecuador de las cuales se capturaron las zonas de estudio, midiendo la distancia euclidiana en metros desde el centroide de cada parroquia hasta el cuerpo de agua más cercano.

0.3 Metodología aplicada (EDA + modelos)

Preprocesamiento y limpieza: El dataset de precipitación presentó valores faltantes en las columnas mensuales (entre 11), los cuales fueron imputados en dos etapas: primero con la mediana histórica de la misma estación para el mismo mes, y en caso de persistir, con la mediana general del mes a nivel nacional. Esta decisión evita sustituir meses sin reporte por cero, que representaría un valor físicamente distinto. Las coordenadas geográficas

y los valores de precipitación se encontraban en formato de coma decimal (estándar europeo), por lo que fueron convertidos a punto decimal antes del procesamiento numérico. No se encontraron registros duplicados en ninguno de los datasets. El shapefile de parroquias fue filtrado a las provincias de Los Ríos y Guayas, obteniendo el subconjunto de análisis.

Construcción de la variable objetivo: Dado que ninguna fuente disponible provee etiquetas de riesgo predefinidas a nivel de parroquia, la variable objetivo fue construida mediante un índice de riesgo compuesto. Se normalizaron tres variables entre 0 y 1: precipitación acumulada promedio, pendiente aproximada y distancia a cuerpos de agua (esta última invertida, ya que menor distancia implica mayor riesgo). El índice resultante corresponde al promedio aritmético de estas tres variables normalizadas. Finalmente, se aplicaron umbrales por percentiles 33 y 66 para asignar las categorías bajo, medio y alto, garantizando un balance aproximado entre clases.

Análisis Exploratorio de Datos (EDA): El EDA incluyó: análisis de la distribución de precipitación acumulada anual mediante histogramas con estimación de densidad kernel; visualización de la estacionalidad de precipitación mensual promedio en la zona de estudio; análisis de correlación entre altitud y precipitación acumulada; y mapas de distribución espacial de estaciones meteorológicas coloreadas por nivel de precipitación sobre los polígonos parroquiales. Este análisis permitió identificar que la zona costera de Guayas concentra los mayores valores de precipitación, mientras que Los Ríos presenta una distribución más homogénea.

Modelos de clasificación: Se implementaron cuatro algoritmos de aprendizaje automático supervisado, descritos a continuación.

Regresión Logística: Se configuró con clasificación multinomial mediante el solver lbfgs, con un máximo de 1000 iteraciones para garantizar la convergencia. Las variables predictoras fueron escaladas previamente con StandardScaler.

Árbol de Decisión: Se limitó la profundidad máxima a 8 niveles para evitar sobreajuste. Este modelo constituye uno de los componentes obligatorios del ensamble.

Random Forest: Se configuró como un ensamble interno de árboles de decisión (n_estimators por defecto), entrenado sobre las mismas variables predictoras, aprovechando su menor sensibilidad al sobreajuste respecto a un

árbol individual gracias al submuestreo aleatorio de datos y características en cada división.

Modelo ensemble (votación suave): Se construyó un clasificador de votación suave (soft voting) que combina los cuatro modelos anteriores. Esta estrategia promedia las probabilidades predichas por cada modelo, lo que produce estimaciones más robustas que la simple votación por mayoría.

0.4 Implementación SVM

Se implementó un clasificador de Máquinas de Vectores de Soporte (SVC) con kernel radial (rbf), habilitando el cálculo de probabilidades (probability=True) necesario para la construcción posterior de las curvas ROC, y un parámetro de regularización C=1.0. Dado que SVM es sensible a la escala de las variables, el modelo se entrenó sobre los datos ya estandarizados con el mismo StandardScaler utilizado para la Regresión Logística. El modelo obtuvo un F1-Score ponderado de 0.8056 sobre el conjunto de prueba.

0.5 Construcción del modelo ensemble (RL + DT + SVM + RF)

Se incorporó un Árbol de Decisión (max_depth=8) como componente adicional obligatorio del ensemble, y se combinó junto con la Regresión Logística, el SVM y el Random Forest mediante un VotingClassifier con votación suave (soft voting), que promedia las probabilidades estimadas por cada modelo base en lugar de contar votos discretos.

Modelo	F1 ponderado (test)
Árbol de Decisión	0.8601
Ensamble (RL+DT+SVM+RF)	0.8601

Cuadro 1: Desempeño del ensemble frente a su componente más fuerte.

0.6 GridSearchCV en SVM

Se aplicó GridSearchCV sobre el modelo SVM, con validación cruzada de 5 particiones y la métrica `f1_weighted`, explorando la siguiente cuadrícula de hiperparámetros: `C` {0.1, 1, 10}, `kernel` {rbf, linear} y `gamma` {scale, auto}.

Los mejores hiperparámetros encontrados fueron `C` = 10, `gamma` = scale, `kernel` = linear, con un F1 ponderado en validación cruzada de 0.9505 y un F1 ponderado de 0.9045 sobre el conjunto de prueba, mejorando notablemente el desempeño respecto al SVM base.

0.7 Curva ROC, AUC – comparación de modelos

Al tratarse de un problema multiclase (riesgo bajo, medio y alto), las etiquetas se binarizaron bajo el esquema One-vs-Rest para calcular la curva ROC y el AUC por clase, promediando de forma macro para cada uno de los seis modelos evaluados: Regresión Logística, Árbol de Decisión, Random Forest, SVM, SVM optimizado (GridSearch) y el Ensamble.

El SVM optimizado mediante GridSearchCV alcanza el AUC macro más alto, superando incluso al modelo ensamble. Esto indica que, para este conjunto de datos, el ajuste fino de hiperparámetros de un solo modelo aportó mayor beneficio que la combinación de varios clasificadores.

Modelo	AUC macro	AUC micro
SVM optimizado (GridSearch)	0.9966	0.9943
Ensamble (RL+DT+SVM+RF)	0.9728	0.9728
SVM	0.9592	0.9739
Random Forest	0.9524	0.9490
Regresión Logística	0.9320	0.9467
Árbol de Decisión	0.8929	0.8929

Cuadro 2: Comparación de AUC entre los seis modelos evaluados.




Figura 1: Curvas ROC macro-promedio por modelo.

0.8 Comparación explícita: Modelo Base (RL) vs Árbol de Decisión vs Modelo Optimizado

Complementando la comparación general de AUC, se construyó una tabla específica que contrasta el modelo base (Regresión Logística), el Árbol de Decisión y el SVM optimizado mediante GridSearchCV, en términos de Precisión, Recall y F1-Score ponderados sobre el conjunto de prueba:

Modelo	Precisión	Recall	F1-Score
Regresión Logística (base)	0.XXXX	0.XXXX	0.XXXX
Árbol de Decisión	0.XXXX	0.XXXX	0.XXXX
SVM optimizado (GridSearch)	0.XXXX	0.XXXX	0.XXXX

Cuadro 3: Comparación explícita entre modelo base, árbol de decisión y modelo optimizado.

Más allá del AUC, es necesario justificar cuál métrica resulta más pertinente para la gestión del riesgo de inundación por parroquia. En este contexto se

prioriza el **Recall** sobre la Precisión, dado que un falso negativo —clasificar como riesgo bajo o medio a una parroquia que en realidad es de riesgo alto— tiene un costo humano y económico considerablemente mayor que una falsa alarma (falso positivo). Por ello, al seleccionar el modelo final se privilegia aquel que maximiza el Recall para la clase de riesgo alto, incluso si esto implica sacrificar algo de Precisión.

0.9 Discusión y limitaciones del estudio

Los resultados obtenidos deben interpretarse considerando varias limitaciones. Primero, el tamaño reducido de la muestra (parroquias de Guayas y Los Ríos, con una porción aún menor destinada al conjunto de prueba) implica que los valores de AUC cercanos a 1.0 deben tomarse con cautela, ya que pueden no reflejar el desempeño del modelo ante un volumen de datos mayor.

Segundo, la variable objetivo es un índice compuesto construido mediante umbrales por percentiles, y no una etiqueta de riesgo observada a partir de eventos históricos validados por el SNGRE, por lo que representa una aproximación técnica y no una medición directa del riesgo real.

Tercero, la altitud y la pendiente se estiman mediante el muestreo aleatorio de puntos dentro de cada polígono parroquial vía datos SRTM, lo que introduce variabilidad en parroquias de forma irregular o gran extensión.

Finalmente, la variable de densidad poblacional no logró integrarse al modelo final por incompatibilidad de columnas, y el estudio se limita geográficamente a Guayas y Los Ríos, por lo que sus resultados no son generalizables a otras provincias sin un reentrenamiento específico.

0.10 Conclusiones finales

El modelo ensamble (Regresión Logística + Árbol de Decisión + SVM + Random Forest) ofrece el mejor equilibrio general entre F1-Score y AUC micro entre los modelos evaluados, por lo que se recomienda como modelo de producción para la aplicación web de visualización geográfica del riesgo.

No obstante, el SVM optimizado mediante GridSearchCV alcanzó el AUC

macro más alto de forma individual, lo que sugiere que, para este conjunto de datos particular, el ajuste fino de un solo modelo aportó un beneficio comparable —e incluso superior en esta métrica— al de combinar varios clasificadores.

Como trabajo futuro, se recomienda resolver la integración de la densidad poblacional, incorporar la variable de porcentaje de área urbanizada actualmente ausente, y validar la variable objetivo contra registros históricos reales de eventos adversos del SNGRE para reducir la dependencia de un índice compuesto por umbrales.